


# m1r3pipelines

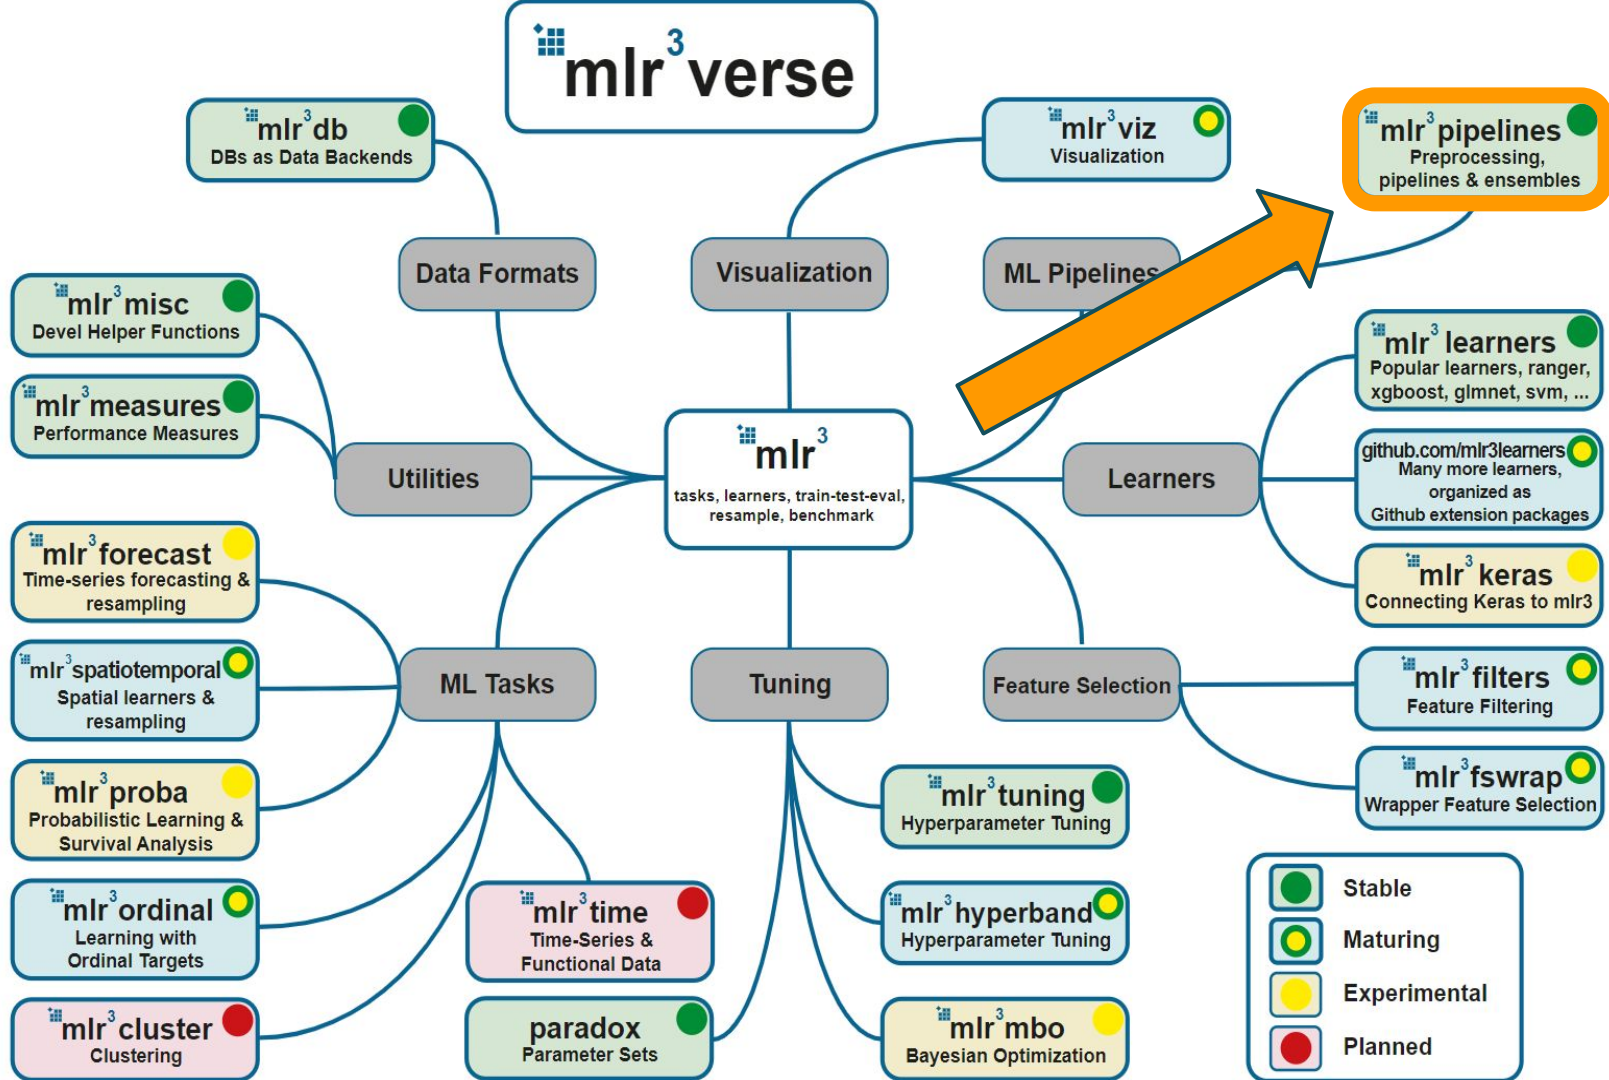


łączenie operacji uczenia maszynowego w potoki

# czym jest mlr3?


- framework do machine learningu w R
- zbudowany na systemie klas R6
- zawiera tylko kluczowe funkcjonalności  
(taski, modele, trenowanie, predykcja, resampling)
- rozszerzany przez pod-paczki





# dłaczego mlr3 nie wystarcza?

- proste tworzenie tasków i modeli
- problem przy automatyzacji przetwarzania danych (np. przy preprocessingu)
- konieczność przebudowy kodu przy zmianie modelu
- brak wbudowanej agregacji predykcji




# do czego służy mlr3pipelines?

- framework do projektowania przepływu danych pomiędzy komponentami z mlr3

# klasa PipeOp

→ reprezentuje przetworzenie danych wejściowych w jakiś konkretny sposób



# klasa PipeOp (na przykładzie PCA)

```
library(mlr3)
```


```
library(mlr3pipelines)
```

```
> task = TaskClassif$new("iris", as_data_backend(iris), "Species")
```

```
> po = mlr_pipeops$get("pca")
```

```
> po$state
```

```
NULL
```



# klasa PipeOp (na przykładzie PCA)

```
> po$train(list(task))[[1]]$data()
      Species      PC1      PC2      PC3      PC4
1:   setosa -2.684126  0.31939725 -0.02791483 -0.002262437
---
150: virginica  1.390189 -0.28266094  0.36290965  0.155038628


> po$state

Standard deviations (1, ..., p=4):

[1] 2.0562689 0.4926162 0.2796596 0.1543862

Rotation (n x k) = (4 x 4):

...
```





# dostępne PipeOp


```
> mlr_pipeops$keys()
```

```
[1] "boxcox"      "branch"      "chunk"      "classbalancing" "classifavg"  "classweights"
[7] "colapply"    "collapsefactors" "copy"      "encode"      "encodeimpact" "encodelmer"
[13] "featureunion" "filter"      "fixfactors" "histbin"     "ica"         "imputehist"
[19] "imputemean"  "imputemedian" "imputenewlvl" "imputesample" "kernelpca"   "learner"
[25] "learner_cv"  "missind"     "modelmatrix" "mutate"      "nop"         "pca"
[31] "quantilebin" "regravg"     "removeconstants" "scale"      "scalemaxabs" "scalerange"
[37] "select"      "smote"       "spatialsign" "subsample"   "unbranch"    "yeojohnson"
```

```
> mlr_pipeops$get("pca", param_vals = list(rank. = 3))
```


```
PipeOp: <pca> (not trained)
```

```
values: <rank.=3>
```




# PipeOp – kanały

- jak w funkcji – liczba parametrów (inputów) zależy od operatora
- inaczej niż w funkcji – zwraca wiele wyników (w postaci listy)



# klasa Graph




- graf skierowany
- wierzchołki – PipeOpy
- krawędzie – przepływ danych
- przepływ danych odbywa się przez kanały, nie przez PipeOpy



# klasa Graph


```
gr = Graph$new()$  
  add_pipeop(mlr_pipeops$get("copy", outnum = 2))$  
  add_pipeop(mlr_pipeops$get("scale"))$  
  add_pipeop(mlr_pipeops$get("pca"))$  
  add_pipeop(mlr_pipeops$get("featureunion", innum = 2))  
  
gr$  
  add_edge("copy", "scale", src_channel = 1)$  
  add_edge("copy", "pca", src_channel = "output2")$  
  add_edge("scale", "featureunion", dst_channel = 1)$  
  add_edge("pca", "featureunion", dst_channel = 2)
```



# klasa Graph

## - operator %>>%

```
gr = mlr_pipeops$get("copy", outnum = 2) %>%  
  union(list(mlr_pipeops$get("scale"),  
            mlr_pipeops$get("pca")))  
  mlr_pipeops$get("featureunion", innum = 2)
```




# powrót do mlr3

## → PipeOpLearner


```
> gr = mlr_pipeops$get("pca") %>% mlr_pipeops$get("learner", mlr_learners$get("classif.rpart"))
> gr$train(task)
$`classif.rpart.output`
NULL
> gr$predict(task)
$`classif.rpart.output`
<PredictionClassif> for 150 observations:
```

## → GraphOpLearner

```
> lrngrph = GraphLearner$new(gr)
> resample(task, lrngrph, rsmp)
<ResampleResult> of 1 iterations
* Task: iris
* Learner: pca.classif.rpart
```



dziękujemy za uwagę



przykładowy  
graf  
(jak na moje  
do usunięcia)

